

CMP617 - Trabalho Final

Modelagem de Tópicos com Dados de Review de Produtos

Augusto M Giani
2024/01

Apresentação:

- Objetivo
- Corpus
- Aplicação do LDA
- Aplicação do BERTopic
- Conclusão

Objetivo

- Aplicação dos modelos LDA e BERTopic para entender qual melhor se aplica para este corpus, avaliando suas particularidades: Qual modelo retornaria meus “tópicos originais” e possíveis insights sobre outros tópicos que fazem sentido para este corpus.
- Identificar qual modelo apresenta grupos de palavras com melhor interpretação humana dos tópicos (coerência e diversidade altas).

Corpus

- Textos de parte das reviews da amazon até 2023 (> 30mi, 12.000 instâncias utilizadas).
 - Produtos (categorias):
 - *Baby Products;*
 - *Movies and TV;*
 - *Toys and Games;*
 - *Grocery and Gourmet Food.*

Raw

```
{ 'rating': 5.0,
  'title': 'So much easier!',

  'text': 'We love this gate. It's hard to find a nice baby/pet gate that is free-standing AND sturdy. This gate has relatively long legs that support the length, thus, making it pretty sturdy. Most free-standing gates are the foldable type, and, in my opinion, would move a lot. The Richell gate, whoever, works nicely. The length is adjustable, as per the description. And it was fairly easy to put together. We like the gate/walk thru quite a lot also.!',

  'images': [],
  'asin': 'B07875D5G1',
  'parent_asin': 'B07875D5G1',
  'user_id': 'AHPI24Q2J73QFGBSMU6VJMEFUPQQ',
  'timestamp': 1524526106601,
  'helpful_vote': 0,
  'verified_purchase': True}
```

Pré-processados (text)

	rating	title	text	images	asin	parent_asin	user_id	timestamp	helpful_vote	verified_purchase
0	5.0	Disposable Toilet Seat Covers	they were all that the ad espoused and more	[]	B08GY9Z996	B08GY9Z996	AH5I5JBQNXZWNITSUZ4CHAYM2ZWQ	1615049393070	1	True
1	5.0	Five Stars	love these they dont leak as long as you hear ...	[]	B00PTL6VLC	B00R5ZOA2C	AHIP22SXU4PL3E6FBV4QTBQA6KZQ	1475201290000	0	True
2	5.0	Plastic Lifesaving Piece	amazon is a lifesaver when i lost this small p...	[]	B00ZB8O82W	B00ZB8O82W	AGRH5XIRBBJTYZ75VD73TU7JG5LQ	1498863584952	3	True
3	3.0	Flimsy	this was very cute but thin and would not stan...	[]	B082STQQTV	B09XR1D9KH	AG3XEGE35Q3FREJIFMADLJSPGZPA	1598933368461	0	True
4	5.0	Highly recommended	bought as a baby shower gift they absolutely l...	[]	B07BK9HYRY	B07BK9HYRY	AGFSVWXZOIR7KI7TG7LUJ3OTLVGQ	1566656394857	0	True

WordCloud



WordCloud


Palavras com maior TF (Adjetivos):

- Love
- One
- “S”
- Great
- Good
- Time
- Movie
- Much
- Use
- ...

LDA

- Remoção “estendida” de stopwords (get, go, also, ...).
- Remoção de adjetivos.
 - *Possível aplicação de POS neste processamento.*
- 30 tópicos.

LDA



LDA

Topic 0

kids
movie
well
good
even
old
like
great
one
easy

Topic 1

like
much
well
also
little
get
love
one
great
good

Topic 2

perfect
love
one
really
movie
time
get
would
film
great

Topic 6

one
really
well
easy
love
get
little
like
great
much

Topic 7


like
love
great
one
would
well
time
old
baby
little

Topic 8


product
loves
like
really
love
would
little
great
one
good

LDA

Intertopic Distance Map (via multidimensional scaling)



Top-30 Most Relevant Terms for Topic 1 (6.4% of tokens)



1. $\text{saliency}(\text{term } w) = \text{frequency}(w) * [\sum_t p(t | w) * \log(p(t | w)/p(t))]$ for topics t ; see Chuang et. al (2012)
2. $\text{relevance}(\text{term } w | \text{topic } t) = \lambda * p(w | t) + (1 - \lambda) * p(w | t)/p(w)$; see Sievert & Shirley (2014)

LDA - Sem remoção de adjetivos

- Coerência LDA: 0.4155
- Proporção de Palavras Únicas: 0.1533
- Diversidade de Jaccard: 0.6380

LDA - Com remoção de adjetivos


- Coerência LDA: 0.3277
- Proporção de Palavras Únicas: 0.2433
- Diversidade de Jaccard: 0.8315

BERTopic

- Remoção de pontuação, links, caracteres especiais.
- Uso do modelo `all-MiniLM-L6-v2` para fazer as embeddings.
 - Escolha por recomendação da documentação, melhores resultados e mais performático.
- Parâmetros BERTopic:
 - `language = "english"`
 - `nr_topics = 30`
 - `n_gram_range = (1,1)`
 - `n_gram_range = (1,2)`
- Remoção de stopwords pós processamento.
 - Não remoção de adjetivos

BERTopic

Topic Word Scores



BERTopic

- **Topic 0:** Filmes
- **Topic 1:** Café+
- **Topic 2:** Games & Toys
- **Topic 3:** Elogios
- **Topic 4:** Bebês

Topic Word Scores



BERTopic

```
9 print('quantidade de tópicos: ', len(set(topics_BERT)))
10 resultados = topic_model.get_topic_info()
11 resultados.head(15)
```


✓ 0.0s

quantidade de tópicos: 30

Topic	Count	Name	Representation	Representative_Docs	
0	-1	4729	-1_great_like_good_movie	[great, like, good, movie, love, just, really,...]	[this is a really good toy my daughter absolut...
1	0	1449	0_movie_story_season_film	[movie, story, season, film, watch, great, dvd...	[i m another one who loves this series it s as...
2	1	1100	1_coffee_tea_flavor_taste	[coffee, tea, flavor, taste, like, good, choco...	[the flavour of this tea is pretty good not as...
3	2	942	2_game_toy_loves_fun	[game, toy, loves, fun, play, old, loved, gift...	[i bought this item for my daughter last chris...
4	3	688	3_great_product_good_excellent	[great, product, good, excellent, awesome, ok,...]	[great product, great product, great product]
5	4	446	4_bottles_diapers_baby_wipes	[bottles, diapers, baby, wipes, bottle, cups, ...]	[i have used the bambo brand since my daughter...
6	5	418	5_box_fast_delivery_good	[box, fast, delivery, good, price, arrived, br...	[these shipped quickly and were delivered via ...]
7	6	297	6_seat_stroller_bag_car	[seat, stroller, bag, car, chair, easy, diaper...	[i have mixed feelings about the tripp trapp i...

BERTopic bi-gramas

Topic Word Scores



BERTopic - `n_gram_range = (1,1)`

- Coerência BERTopic : 0.6953
- Proporção de Palavras Únicas: 0.8566
- Diversidade de Jaccard: 0.9915

BERTopic - `n_gram_range = (1,2)`

- Coerência BERTopic : 0.6763
- Proporção de **Bi-Gramas** Únicas: 0.9166
- Diversidade de Jaccard: 0.9943

Conclusões

- Conjunto de dados de review:
 - Possível uso de lematização (e.g. *love*, *loves*, *loved*);
 - Adjetivos;
 - Subtópicos.
 - Possível conjunto de dados enviesado (elogios vs *hates*)
- Dificuldade em interpretar o melhor uso de LDA para este conjunto de dados.
 - Sentimento de que somente um conjunto muito específico de parâmetros para fazer funcionar este modelo para este conjunto de dados;
 - Não segui replicando os mesmos parâmetros com LDA e BERTopic.

Conclusões

- BERTopic não só obteve todas as métricas maiores como também teve representatividade bem melhor (tópicos muito mais interpretáveis).
- BERTopic com Bi-gramas mantiveram boa interpretação humana em alguns dos top 10 tópicos, porém piorou e alguns tópicos perderam sentido, apesar da **coerência** e **diversidade** deram valor alto, não encontrei sentido entre algumas palavras de alguns tópicos.

Referências:

- LDA Documentation (<https://blog.echen.me/2011/08/22/introduction-to-latent-dirichlet-allocation/> antes de 10/08/24).
- BERTopic own Documentation (<https://maartengr.github.io/BERTopic/api/bertopic.html> antes de 10/08/24).
- KRISHNAN, Anusuya. *Exploring the power of topic modeling techniques in analyzing customer reviews: a comparative analysis*. arXiv preprint arXiv:2308.11520, 2023.