

Modelagem de Tópicos para Dados de Reviews de Produtos

Augusto M. Giani¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Caixa Postal 15.064 – 91.501-970 – Porto Alegre – RS – Brazil

augusto.giani2@gmail.com

Abstract. *In this study, it was compared the LDA and BERTopic models to analyze Amazon product reviews across four categories. The objective is to evaluate which model better to identify the main topics from the subdataset and generates relevant insights on emerging topics. LDA, known for identifying frequent word patterns, is compared to BERTopic, which combines clustering with embeddings for more precise topic extraction. It was assessed the human-interpretability of the topics generated by each model based on Coherence and Diversity, concluding which is more effective for the given corpus and suggesting additional techniques to enhance the results.*

Resumo. *Neste estudo, foi comparado os modelos LDA e BERTopic para analisar um subconjunto de quatro categorias reviews de produtos da Amazon. O objetivo é avaliar qual modelo melhor identifica os tópicos principais e gera insights relevantes sobre tópicos emergentes. O LDA, conhecido por identificar padrões de palavras frequentes, é comparado ao BERTopic, que combina clustering com embeddings para uma extração de tópicos mais precisa. Foi avaliado a interpretação dos tópicos gerados por cada modelo com base na Coerência e Diversidade, concluindo qual é mais eficaz para o corpus em questão e sugerindo técnicas adicionais para aprimorar os resultados.*

1. Introdução

Neste trabalho, são comparados dois dos principais modelos de Topic Modeling: Latent Dirichlet Allocation (LDA) e BERTopic. O objetivo central é avaliar qual desses modelos oferece a melhor adequação para um corpus de quatro categorias de reviews de produtos da Amazon, levando em consideração não apenas a capacidade de identificação dos tópicos principais (categorias originais), mas também a geração de insights sobre outros tópicos emergentes que podem possuir alguma relevância.

Para essa análise, examinam-se algumas particularidades de cada modelo. O LDA, um dos métodos mais tradicionais de modelagem de tópicos, é amplamente conhecido por sua capacidade de identificar padrões de palavras que ocorrem com frequência em textos. Já o BERTopic, um modelo mais atual, combina técnicas de clustering com embeddings e promete uma abordagem visivelmente mais eficaz na extração de tópicos, especialmente em contextos onde a semântica desempenha um papel crítico [1].

Os objetivos específicos deste trabalho incluem a identificação de qual dos modelos oferece agrupamentos de palavras que apresentam uma melhor interpretação humana dos tópicos, como também avaliando quais grupos obtém maiores índices de Coerência e

Diversidade. A Coerência é medida pela capacidade do modelo de agrupar tokens distintos que fazem sentido juntas em um determinado tópico, enquanto a diversidade refere-se à capacidade de gerar tópicos distintos e não redundantes. Ambos os aspectos são cruciais para determinar a utilidade prática do modelo.

Através desta investigação, é concluído qual modelo é mais eficaz para o corpus em estudo e também fornecido insights sobre possíveis subtópicos, possibilidades de pré-processamento e também outras técnicas que poderiam ser aplicadas junto à modelagem de tópicos para aprimorar os resultados.

2. Trabalhos Relacionados

No estudo de A. Krishnan e Kennedyraj [2], os autores exploram não só o uso de LDA e BERTopic, mas também os modelos LSA, Top2Vec e NMF para modelagem de tópicos em conjunto de dados de reviews de experiência do usuário tirados do Ministério da Economia dos Emirados Árabes Unidos e Reviews de hotéis de Chicago. O objetivo do trabalho foi também avaliar a performance dos modelos nos diferentes corpus.

Concluindo o trabalho, os autores reconheceram problemas na avaliação dos resultados utilizando as mesmas métricas aplicadas neste trabalho, pois, segundo eles as métricas de coerência e diversidade dependem do corpus analisado para estes scores tragam alguma interpretabilidade dos resultados em relação a o quanto os tópicos foram bem clusterizados e suas representações tivessem sentido em uma análise humana

Neste trabalho também foi-se avaliado a questão do quanto as métricas representavam uma "melhora" ou "piora" em relação à interpretabilidade humana e se identificou a mesma particularidade devido ao conjunto de dados: não necessariamente porque os scores aumentaram que os resultados realmente ficaram "melhores".

3. Metodologia

3.1. Corpus

O Corpus analisado faz parte de um subconjunto de 12000 exemplos aleatórios extraídos de mais 30 milhões de instâncias de quatro categorias de produtos da Amazon [3]. O idioma escolhido das reviews foi Inglês.

As quatro categorias escolhidas para o estudo foram:

- *Baby Products*;
- *Movies and TV*;
- *Toys and Games*;
- *Grocery and Gourmet Food*.

Cada categoria simboliza um tópico que é buscado recuperar ao rodar os modelos de Topic Modeling. Quanto mais significativa a review, ela simboliza muito bem o seu grupo, como por exemplo:

- *"Easy to set up, provided a comfortable sleep for our 2 year old grandson and allowed him to safely roll over! Recommended it to other grandparents!"*: Baby Products
- *"Great family movie, even my teenager put down their phones to watch it"*: Movies and TV

recomendação de conteúdo. Atualmente, com o avanço das técnicas de aprendizado de máquina e o surgimento de modelos mais sofisticados como o BERTopic, técnica também abordada neste trabalho [5].

Neste estudo, o LDA foi aplicado com algumas particularidades específicas para melhorar a qualidade dos tópicos gerados. Foram removidas stopwords adicionais, como: get, go, also. Além disso, foram removidos adjetivos que poderiam distorcer a formação dos tópicos. Com essas adaptações, o modelo LDA foi configurado para gerar 30 tópicos distintos, buscando maximizar a interpretação e a relevância dos resultados para o corpus em questão.

3.4. BERTopic

Como mencionado anteriormente, O BERTopic é um modelo de Topic Modeling mais recente que combina técnicas de clustering com embeddings para identificar tópicos em grandes corpus. Diferente do LDA, que depende da frequência de co-ocorrências de palavras, o BERTopic utiliza representações semânticas das palavras através de modelos de embeddings, permitindo uma compreensão mais profunda e contextual das relações entre termos. Essa abordagem é particularmente útil em contextos onde a semântica desempenha um papel crucial, como em textos complexos ou heterogêneos, onde as simples coocorrências podem não capturar completamente o significado subjacente. Devido à essa sua capacidade singular, o BERTopic foi considerado uma evolução significativa em relação ao LDA, especialmente para análises que requerem maior precisão e relevância contextual. Um dos grandes pontos de evolução e observado neste trabalho foi a melhoria na representação dos tópicos.

Neste estudo, o BERTopic foi aplicado com algumas adaptações para otimizar os resultados. Foi realizado a remoção de pontuação, links e caracteres especiais para limpar o texto e focar nos elementos mais relevantes para a modelagem dos tópicos. Também foram removidos os adjetivos e a remoção de stopwords foi realizada apenas depois do fit do modelo. Além disso, foi utilizado o modelo de embeddings `all-MiniLM-L6-v2`, escolhido por recomendação da documentação oficial do BERTopic [1]. Este modelo foi selecionado por oferecer um bom equilíbrio entre precisão e desempenho. Além destas particularidades, também foram ajustados os seguintes hiperparâmetros:

```
language = "english"  
nr_topics = 30  
n_gram_range = (1, 1)
```

Foi feito o experimento de utilizar bi-gramas para representação dos tópicos para `n_gram_range = (1, 2)`, para abrir a possibilidade de palavras compostas aparecerem nas representações, ou melhorar nas métricas.

3.5. Métodos de avaliação

A medida de Coerência considera a probabilidade de coocorrência de palavras dentro de um tópico. O método utilizado calcula a similaridade entre as palavras de um tópico com base em uma matriz de coocorrência de palavras extraída do corpus. Quanto maior a coerência, mais relacionadas e coesas são as palavras de um tópico, indicando que o modelo gerou tópicos que possivelmente podem ter

um significado interpretável e consistente. Foi-se utilizado o modelo de coerência da `gensim.models.coherencemodel` em Python 3.11.

Para medidas de diversidade, utilizou-se a Proporção de palavras únicas, que nada mais é que a proporção de palavras singulares em um tópico em relação ao corpus inteiro; também, a medida de diversidade pela distância de Jaccard, que se resume em:

$$D_J(T_i, T_j) = 1 - \frac{|T_i \cap T_j|}{|T_i \cup T_j|}$$

- $D_J(T_i, T_j)$: é a distância de Jaccard entre os tópicos T_i e T_j .
- $|T_i \cap T_j|$: é o número de palavras em comum entre os tópicos T_i e T_j .
- $|T_i \cup T_j|$: é o número total de palavras únicas nos tópicos T_i ou T_j .

A diversidade total então é a soma total entre todos os pares de tópicos, dividido pela combinação dois a dois de todos os tópicos gerados.

4. Resultados

Foram avaliados as métricas de Coerência e Diversidade para ajudar na avaliação da geração dos tópicos gerados, porém, como critério principal foi-se avaliado principalmente a interpretação humana quanto a representação dos tópicos. A razão disto é que as classificações precisam ter alguma compreensão humana para fazerem algum sentido e terem alguma utilidade prática, sem isso, para qualquer aplicação fica difícil pensar como fazer a utilização direta (sem outros tratamentos) dos tópicos gerados.

4.1. LDA

Os resultados da aplicação de LDA demonstram uma variação significativa nas métricas de coerência, proporção de palavras únicas e diversidade de Jaccard ao comparar as abordagens com e sem remoção de adjetivos. No entanto, as representações dos tópicos gerados foram insatisfatórias, mostrando predominantemente adjetivos, o que compromete a interpretabilidade dos tópicos.



Figura 2. Representação dos tópicos gerados por LDA.

Sem remoção de adjetivos:

- Coerência: 0.4155
- Proporção de Palavras Únicas: 0.1533
- Diversidade de Jaccard: 0.6380

Com remoção de adjetivos:

- Coerência: 0.3277
- Proporção de Palavras Únicas: 0.2433
- Diversidade de Jaccard: 0.8315

4.2. BERTopic

Os resultados obtidos com o BERTopic mostraram alta eficácia na modelagem de tópicos. Abaixo é possível ver as representações dos tópicos usando apenas unigramas:




Figura 3. Dez primeiros tópicos gerados mais relevantes em relação ao corpus.

Unigramas:

- Coerência BERTopic : 0.6953
- Proporção de Palavras Únicas: 0.8566
- Diversidade de Jaccard: 0.9915

O fitting do BERTopic utilizando bigramas pode ser observado abaixo, porém a maior diferença é que muitas representações de tópicos tiveram o acréscimo de um adjetivo principalmente, o que não adiciona muito à interpretabilidade ou à relevância dos resultados.




Figura 4. Dez primeiros tópicos gerados através de bigramas.

Bigramas

- Coerência BERTopic : 0.6763
- Proporção de Palavras Únicas: 0.9166
- Diversidade de Jaccard: 0.9943

Os resultados obtidos, principalmente utilizando unigramas, indicam não apenas uma alta qualidade na distinção dos tópicos, mas também uma interpretação eficaz e relevante dos mesmos.

5. Conclusões

A análise dos dados de reviews de produtos revelou várias áreas para melhoria no processamento e na modelagem dos tópicos. É notável a quantidade de adjetivos no corpus, o que pode ter afetado na interpretação dos resultados.

O conjunto de dados apresenta um viés evidente, com uma predominância de feedback positivo e diferenças na quantidade de reviews relevantes entre categorias (categorias com menos reviews específicas do que outras). Esse desequilíbrio pode afetar a representatividade dos tópicos e limitar a aplicabilidade dos resultados.

A aplicação do LDA revelou dificuldades na interpretação e na adaptação do modelo para o conjunto de dados de reviews de produtos. Observou-se que apenas um conjunto muito específico de parâmetros e técnicas de pré-processamento poderia tornar o LDA funcional para este corpus, o que sugere a necessidade de ajustes precisos para obter resultados significativos. Por não apresentar grandes avanços, os parâmetros utilizados para o LDA não foram replicados no BERTopic, no intuito de explorar melhores opções de modelagem usando BERTopic.

O BERTopic superou o LDA em todas as métricas, oferecendo tópicos mais representativos e interpretáveis. Demonstrou eficácia ao identificar subtópicos específicos, como o tema de carrinhos de bebê, o que reflete sua capacidade de captar detalhes contextuais com maior precisão. No entanto, ao utilizar Bi-gramas, embora a interpretação humana de alguns tópicos tenha permanecido boa, outros tópicos apresentaram perda de sentido. Apesar das métricas de coerência e diversidade terem sido altas, a interpretação de alguns tópicos foi prejudicada, evidenciando que nem todos os tópicos mantiveram a clareza desejada.

Como possíveis melhorias, a lematização pode ser útil para uniformizar variações de termos, visto o grande número de adjetivos presentes no corpus (love, loved, loves), o que pode ter impactado a clareza dos tópicos gerados. A utilização de Part of Speech Tagging (POS) também pode ser considerada para aprimorar a seleção de termos relevantes e otimizar a qualidade dos tópicos pela remoção não só de adjetivos mas outras formas de linguagem irrelevantes para a tarefa.

Referências

- [1] BERTopic own Documentation (<https://maartengr.github.io/BERTopic/api/bertopic.html> antes de 10/08/24).
- [2] KRISHNAN, Anusuya. Exploring the power of topic modeling techniques in analyzing customer reviews: a comparative analysis. arXiv preprint arXiv:2308.11520, 2023.
- [3] Conjunto de dados de Amazon Reviews: HuggingFace
- [4] LDA Documentation (<https://blog.echen.me/2011/08/22/introduction-to-latent-dirichlet-allocation/> antes de 10/08/24)
- [5] HOFFMAN, Matthew D. et al. Stochastic variational inference. Journal of Machine Learning Research, 2013.